

ביולוגיה חישובית

89-512 80-512

2024

תרגיל רשתות נוירונים – SOM

ביולוגיה חישובית

תרגיל 3

מהו SOM (Self Organizing Map) ?

SOM הינה רשת נוירונים פשוטה שתפקידה לעזור בכיצוע ובעיקר בהצגת הקבוצות (clustering). בד"כ משתמשים במטריצה דו ממדית המאותחלת כך שלכל תא (נוירון) משיוך וקטור של מספרים אקראיים; אורכו של הווקטור הוא כאורך הווקטור המייצג את דוגמאות הקלט. עבור כל דוגמא בקלט מחפשים את הווקטור הדומה לה ביותר, ואז "מקרבים" את הווקטור הזה (שבאופן התחלתי היה כאמור אקראי) לדוגמא ששויכה אליו. גם את הווקטורים הנמצאים בסביבת הווקטור שנבחר מקרבים לאותה דוגמא, אם כי בשיעור מתון יותר (את האפקט הזה ניתן להשיג למשל על ידי חוק שאומר למשל שהווקטור הנבחר ינוע לקראת הדוגמא ב-30%, תאים במעגל הראשון מסביבו יקודמו ב-20%, תאים במעגל השני ב-10% וכו'). בסיום התהליך ימופו קלטים דומים לאזורים סמוכים במטריצה, והווקטורים המשוויכים לאזורים אלו יהיו דומים במידה מסוימת לקלטים שאותם הם מייצגים.

מהי מטרת התרגיל?

מטרת התרגיל היא ליישם SOM על ספרות. באתר ימצא קובץ קלט `digits_test.csv` שבו נתונות הספרות 0-9 כמטריצה בגודל 28×28 פיקסלים של גוויי אפור. מבנה הקובץ בפורמט CSV הוא 10,000 שורות כאשר כל שורה מכילה 784 ערכים כאשר 28 המספרים הראשונים מייצגים את השורה הראשונה במטריצה, 28 המספרים הבאים את השורה השנייה וכו' עבור כל 28 השורות במטריצה. הערכים בפיקסלים מייצגים גוויי אפור בטווח בין 0 (לבן) לבין 255 (שחור).


בנוסף יש קובץ ששמו `digits_test_keys.csv` המכיל את הזהוי של הספרות שמופיעות בקובץ הדאטה לפי אותו הסדר, כלומר בשורה הראשונה מופיעה הזהות של הספרה הראשונה, בשורה השנייה הזהות של הספרה השנייה וכו' כך עבור 10,000 הספרות. הקובץ הזה הוא לצורך הבדיקות, התצוגה, והדו"חות בלבד, אין להשתמש בו במהלך בניית הרשת.

על התוכנית לייצר רשת SOM (ריבועית (יותר פשוט) או הקסגונית (קצת יותר מורכב)) בגודל של כ 100 תאים. (שימו לב שיתכן שכדאי לחשוב על שיטה יותר מתוחכמת להגדיל את הערכים הראשוניים בכל נירון מאשר הגרלה רנדומית לחלוטין של מספרים בין 0 ל 255). כאשר בסוף התהליך כל נירון אמור להיות הנציג של מספר מחרוזות בקלט. הפלט יציג את רשת ה-SOM שנוצרה. את הרשת אפשר להציג בצורה שונות: במינימום, יש לרשום עבור כל נירון את זהות הספרה הדומיננטית שהוא מייצג ואת אחוז ההופעה שלה. דוגמא ברשת מוקטנת בגודל 5×5

2(89)	3(60)	3(95)	3(95)	6(40)
2(50)	2(45)	3(70)	3(70)	5(15)
4(24)	2(30)	8(35)	9(35)	0(60)
4(40)	4(70)	8(70)	9(55)	0(40)
4(30)	4(65)	8(20)	0(24)	0(70)

התצוגה הזאת פירושה למשל שבניירון בשורה הראשונה מצד שמאל, הספרה הדומיננטית היא 2 והיא מהווה 89% מכלל הספרות שמופו לניירון זה. לצורך החישוב הזה ניתן להשתמש בקובץ `digits_test_keys.csv` שיועד מה הסיווג הנכון לכל ספרה בקלט.

דרך הצגה יותר טובה היא להשתמש בערכים של הוקטור שנמצא בכל ניירון בסוף הריצה וליצור מהם את תמונת הניירון, תוך שימוש בספריות גרפיות סטנדרטיות. שוב בדוגמא של רשת בגודל 5X5



כמובן שאתם יכולים לחשוב על צורות הצגה נוספות – ככל שהצגה תהיה מושקעת יותר כך ישתפר הציון.

כמובן שיש לחזור על תהליך יצירת ה SOM מספר רב של פעמים ולהגיש בדו"ח את הפתרון הטוב ביותר. אנחנו לא מגבילים מראש את מספר מחזורי הלימוד, אבל יש לדאוג לכך שריצה בודדת לא תיקח יותר מ-3 דקות על מחשב סטנדרטי (על מנת שהבודק לא יצטרך להריץ תוכניות ארוכות)

שאלות התרגיל

- איך איתחלתם את ערכי הניירונים?
- באיזה אופן קרבתם את התא עליו הוטל קלט מסוים לאותו קלט ובאיזה אופן שונו שכניו?
- האם הגודל המוצע של הרשת מתאים לדעתכם לייצוג אוכלוסיית ספרות זו?
- כיצד בחרתם את הפתרון להגשה מבין הפתרונות השונים.

יש לנמק את תשובותיכם בעזרת הרצות ונתונים רלוונטיים.

תאריך ואופן הגשה

- יש להגיש את קוד התוכנית וקובץ הרצה. על הקבצים המוגשים להכיל את כל הקבצים הנלווים - כך שלא יהיה צורך להתקין ספריות או התקנות בנפרד. על התרגיל לרוץ על מחשב וינדוס סטנדרטי או שרתי הלינוקס של המחלקה למדעי המחשב. בכל מקרה

23/6/24

אחר יש לקבל אישור מראש מהמתרגלים. יש לציין במפורש בתוך הדו"ח האם התרגיל

נועד לרוץ ב WINDOWS או LINUX

-
- דו"ח המכיל התייחסות מפורטת לסעיפי התרגיל ותשובות לשאלות שהוצגו לעיל,

יש להגיש את העבודה עד 18.7.24 דרך האתר.
מותר להגיש בזוגות.

ב ה צ ל ח ה !